

A oferta certa, para o cliente certo

Hoje os cupons são distribuídos de forma uniforme: cada cliente recebe qualquer uma das 10 ofertas do portfólio, com a mesma chance. Analisamos um teste de 30 dias para responder: **quanto ganhamos se cada envio for escolhido para o cliente que o recebe?**

17 mil

clientes acompanhados
por 30 dias

76 mil

ofertas enviadas em 6
ondas

306 mil


eventos de compra,
recebimento e
visualização

38%

dos envios convertem
com a distribuição atual

Enviar a oferta errada custa **duas vezes** mais caro

1 A resposta varia muito entre ofertas - e entre clientes



A conversão vai de **17% a 60%** conforme a oferta e a melhor escolha muda com o perfil e o momento de cada cliente.

2 Parte da verba não influencia ninguém

R\$ 48 mil

de R\$ 162 mil pagos em descontos no teste

30% dos descontos foram ativados **sem o cliente ter visto a oferta**: ele compraria de qualquer forma - a verba não mudou o comportamento.

Distribuir melhor não é só converter mais: é **parar de pagar desconto onde ele não muda a decisão** do cliente.

Um modelo que estima a chance de resposta de cada cliente a cada oferta

1

Aprende com o comportamento

Para cada envio do teste, o modelo vê o que o cliente fez antes (frequência e valor de compras, quando comprou pela última vez, como reagiu a ofertas anteriores) junto com o perfil e as características da oferta.

2

Estima a chance de conversão para as 10 ofertas

Para qualquer cliente, o modelo calcula a probabilidade de resposta a cada uma das 10 ofertas do portfólio.

3

Recomenda a melhor oferta para cada envio

A régua de decisão é transparente e ajustável: hoje maximiza conversão; com dados de margem, passa a maximizar valor (ganho vs custo do desconto).

■ É confiável?

8 de 10

vezes o modelo ordena corretamente quem converte (AUC 0,80), medido em clientes que ele nunca viu


2,1x

mais conversão no grupo que o modelo aponta como mais propenso vs a média

As probabilidades são **calibradas**: quando o modelo diz 60% de chance, cerca de 60% convertem de fato, o que permite usá-las em contas de negócio (projeções de verba e retorno).

■ RESULTADO

Enviar a oferta recomendada aumenta a conversão em **71%**



No próprio teste, os envios que, por sorteio, coincidiram com a recomendação do modelo converteram **66%**, contra **38,6%** da distribuição atual (**+27 pontos, +71%**).

A personalização também supera a alternativa simples de mandar a oferta campeã para todos (**62,8%**) e, na prática, concentra os envios em ofertas de **baixo custo**: mais de 95% das recomendações têm desconto de até R\$ 3 ou custo zero (informativas), em vez de gastar desconto alto com quem não precisa dele.

Comparação em 15,2 mil envios de teste, clientes fora do treinamento.
IC 95% para o grupo recomendado: 63,6%–68,3%.
Como o envio original foi aleatório, os grupos são comparáveis (quase-experimento).

O que isso significa em escala

+24 a 27 mil

conversões adicionais a cada 100 mil envios
(de 38,6 mil para 63-66 mil)

R\$ 32

gasto mediano do cliente durante a validade
de uma oferta convertida, cada ponto de
conversão movimenta receita

até 30%

da verba de descontos hoje ativada sem
influência, endereçável com melhor
direcionamento

1

Piloto A/B (2-4 semanas)

Política atual vs política do modelo em uma fração dos envios confirma o
ganho em produção antes de escalar.

2

Régua de valor

Incorporar margem por pedido e custo de desconto à decisão: de “maximizar
conversão” para “maximizar retorno por envio”, sem retreinar o modelo.

3

Evolução para incrementalidade

Com grupo de controle contínuo, medir o efeito causal de cada oferta (uplift) e
suspender envios a quem converteria sozinho.

■ Por que começar agora

A solução usa dados que já coletamos, roda sobre o portfólio atual
de ofertas e a régua de decisão é auditável. O risco é controlado pelo
piloto A/B e o custo de esperar é seguir convertendo 39% dos envios
onde a oferta certa converte 66%, com 30% da verba de desconto
sem retorno.

Estimativas baseadas no teste de 30 dias (17 mil clientes); números detalhados e metodologia nos notebooks do repositório.